Clustering K-prototypes

Équipe 19 – ANACLET Kylian, BIN DAIVIN Muhamad Zaiinizee, CHENNOUF Younes, KEBAIRI Ilyes

2025-12-10

Le jeu de données contient à la fois des variables numériques et catégorielles (région, condition d'éclairage, condition atmosphérique, etc.). L'algorithme K-means classique n'est donc pas adapté, car il repose sur la distance euclidienne, qui n'a pas de sens pour les variables catégorielles, même après encodage one-hot.

Il est préférable d'utiliser **K-prototypes**, qui combine la distance euclidienne pour les variables numériques et une mesure de dissimilarité spécifique pour les variables catégorielles. Cet algorithme permet ainsi d'obtenir des clusters plus fiables et cohérents.

K-prototypes

L'algorithme K-prototypes implémente la méthode de partitionnement par minimisation de la distance entre les observations et les centres de clusters. Plus précisément, il cherche à minimiser la fonction suivante :

$$\min_{c_1,\ldots,c_k} \sum_{k=1}^{K} \sum_{i,G(i)=k} d(x^{(i)}, c_k)$$

où $d(x^{(i)}, c_k)$ représente la distance entre l'observation $x^{(i)}$ et le centre du cluster c_k. Cette distance combine la distance euclidienne pour les variables numériques et une mesure de dissimilarité pour les variables catégorielles.

La minimisation est réalisée automatiquement par la fonction `kproto()` à travers un processus itératif. L'algorithme affecte chaque observation au cluster dont le centre est le plus proche, puis recalcule les centres, et répète ces étapes jusqu'à convergence. Le résultat de cette minimisation est observable via `tot.withinss`, qui représente la somme totale des distances intra-clusters.

A. Chargement et préparation des données

Le jeu de données final étant **très volumineux**, un échantillon aléatoire a été extrait pour faciliter le traitement et le clustering.

```
if(!require(dplyr)) install.packages("dplyr")
```

```
## Le chargement a nécessité le package : dplyr
```

```
##
## Attachement du package : 'dplyr'
```

```
## Les objets suivants sont masqués depuis 'package:stats':
##
##     filter, lag

## Les objets suivants sont masqués depuis 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
library(dplyr)

set.seed(321)
n_sample <- 5000

# Exécuter le script « nettoyage_donnees_clustering.Rmd », situé dans le dossier clustering, afin de gé
df <- read.csv("../data/donnees_clustering.csv")
df_complete <- df %>%
  mutate(across(where(is.character), as.factor)) %>%
  select(agg, lum, atm, col, vma)

# Convertir toutes les variables de type character en factor
# Puis sélectionner uniquement les 5 variables retenues pour le clustering
df <- df %>%
  mutate(across(where(is.character), as.factor)) %>%
  select(agg, lum, atm, col, vma)

# On tire par hasard 1000 accidents
df <- df[sample(nrow(df), n_sample), ]
```

On sélectionne ces 5 variables (agg, lum, atm, col, vma) car elles capturent les conditions principales de l'accident (localisation, luminosité, météo, type de collision et vitesse autorisée) et donnent les meilleurs résultats de clustering.

```r
str(df)
```

```
## 'data.frame':    5000 obs. of  5 variables:
##  $ agg: Factor w/ 2 levels "en agglo","hors agglo": 1 1 1 2 1 1 2 1 1 2 ...
##  $ lum: Factor w/ 5 levels "crepuscule ou aube",..: 2 5 5 5 2 5 1 5 5 1 ...
##  $ atm: Factor w/ 9 levels "autre","brouillard ou fumee",..: 8 3 6 6 6 6 6 6 3 6 ...
##  $ col: Factor w/ 7 levels "3+ veh - en chaine",..: 4 4 3 6 7 5 5 6 7 5 ...
##  $ vma: int  50 50 50 80 50 50 80 50 50 -1 ...
```

B. Verification de la légitimité de clustering

Avant de commencer on doit tout d'abord s'assurer que l'utilisation de la méthode de clustering est légitime ici (s'assurer que les données ne sont pas réparties de façon homogène). Pour ce faire on utilise la méthode statistique en calculant la statistique de Hopkins calculé avec la formule :

$$H = \frac{\sum_{i=1}^{n} x_i}{\sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i}$$

où :

- x_i la distance d'un i-éme point p_i choisi aléatoirement dans notre distribution à tster avec son plus proche voisin dans la même distribution
- y_i **:** la distance d'un i-éme point qi choisi aléatoirement dans une distribution aléatoire uniforme avec son plus proche voisin dans la distribution

Nos hypothèses étant :

- H_0 **:** Les données sont uniformément distribués
- H_1 **:** Les données ne sont pas uniformément distribués

```
if(!require(hopkins)) install.packages("hopkins")
```

```
## Le chargement a nécessité le package : hopkins
```

```
library(hopkins)

numeric_cols <- sapply(df, is.numeric)
n_numeric <- sum(numeric_cols)

if (n_numeric >= 2) {
  h_stat <- hopkins(df[, numeric_cols])
  cat("Statistique de Hopkins :", round(h_stat, 4), "\n")
} else {
  cat("Hopkins non calculable : seulement", n_numeric, "variable numérique (vma).\n")
  cat("   (La fonction nécessite au moins 2 variables numériques)\n")
}
```

```
## Hopkins non calculable : seulement 1 variable numérique (vma).
##    (La fonction nécessite au moins 2 variables numériques)
```

C. Choix du nombre de clusters (k)

On applique l'algorithme k-prototypes pour différentes valeurs de k.

```
set.seed(321)
if(!require(clustMixType)) install.packages("clustMixType")
```

```
## Le chargement a nécessité le package : clustMixType
```

```
if(!require(cluster)) install.packages("cluster")
```

```
## Le chargement a nécessité le package : cluster
```

```
library(clustMixType)
library(cluster)

k_max <- 10
cost <- numeric(k_max)
```

```r
sil_avg <- numeric(k_max)

# Calculer la distance de Gower sur les données non normalisées
d <- daisy(df, metric = "gower")

# Exécuter k-prototypes pour différentes valeurs de k
for (k in 2:k_max) {
  kp <- kproto(df, k, verbose = FALSE)
  cost[k] <- kp$tot.withinss

  sil <- silhouette(kp$cluster, d)
  sil_avg[k] <- mean(sil[, 3])
}

# Plot méthode du coude
plot(2:k_max, cost[2:k_max],
     main = "Méthode du coude pour choisir k",
     type = "b", xlab = "Nombre de clusters (k)",
     ylab = "Somme des distances")
```

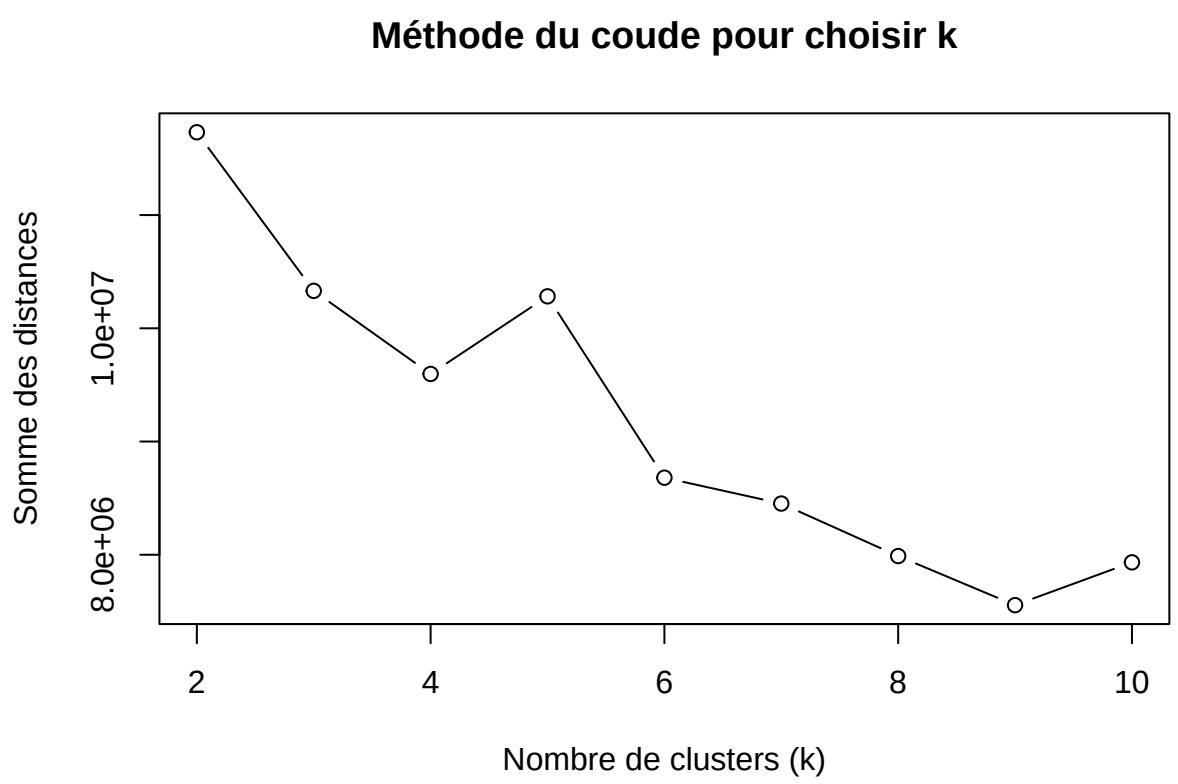


```r
# Plot méthode de la silhouette
plot(2:k_max, sil_avg[2:k_max],
     main = "Méthode de la silhouette pour choisir k",
     type = "b", xlab = "Nombre de clusters (k)",
     ylab = "Silhouette moyenne")
```

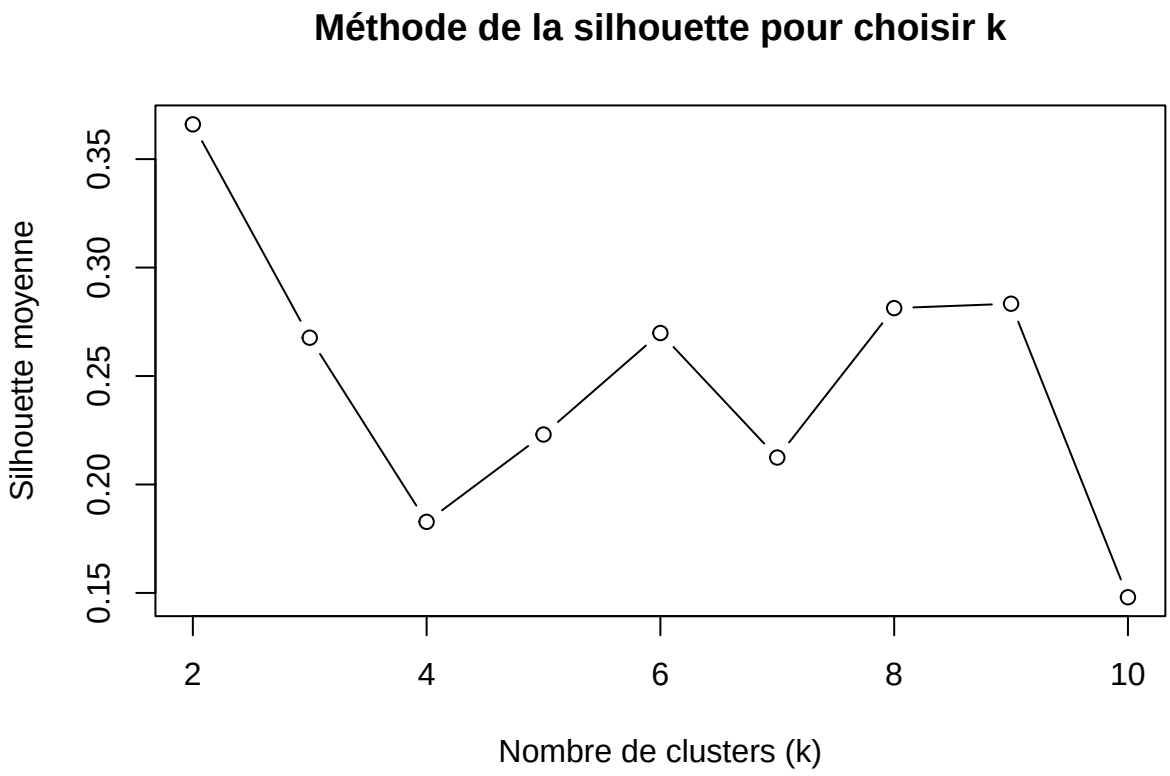

Observations

La méthode du coude montre une stabilisation à partir de k = 4, tandis que l'indice de Silhouette est maximal à k = 2.

Pour choisir le meilleur k, nous testons k = 2, 3 et 4 en comparant leurs indices de qualité.

D. Application de k-prototypes et analyse des résultats

```
set.seed(321)
res_k2 <- kproto(df, k = 2, verbose = FALSE)
res_k3 <- kproto(df, k = 3, verbose = FALSE)
res_k4 <- kproto(df, k = 4, verbose = FALSE)
```

E. Test de la qualité du clustering

Afin d'évaluer la qualité du clustering on évalue les deux indices :

- l'indice de Silhouette pour chaque cluster qui pour chaque élément évalue à quel point un élément est "similaire" par rapport aux autres éléments du même cluster .
- l'indice de Dunn qui est défini comme suit :

$$D = \frac{min.separation}{max.diameter}$$

De plus on veille à adapter cette methode d'évaluation à la methode de clustering utilisée (k-prototype) et ce en utilisant justement la distance de gower qui prend en compte les variables catégorielles

```
if(!require(fpc)) install.packages("fpc")
```

```
## Le chargement a nécessité le package : fpc
```

```
library(cluster)
library(fpc)

dist_gower <- daisy(df, metric = "gower")

evaluer_k <- function(res, k_val) {
  cat("=== k =", k_val, "===\n")
  sil <- silhouette(res$cluster, dist_gower)
  cat("Silhouette moyenne :", round(mean(sil[,3]), 4), "\n")
  cat("Détail :", paste(round(summary(sil)$clus.avg.widths, 4), collapse = ", "), "\n")
  dunn <- cluster.stats(dist_gower, res$cluster)$dunn
  cat("Dunn :", round(dunn, 6), "\n\n")
}

evaluer_k(res_k2, 2)
```

```
## === k = 2 ===
## Silhouette moyenne : 0.366
## Détail : 0.3327, 0.3853
## Dunn : 0.001128
```

```
evaluer_k(res_k3, 3)
```

```
## === k = 3 ===
## Silhouette moyenne : 0.2677
## Détail : 0.2861, 0.3107, 0.2277
## Dunn : 0.001133
```

```
evaluer_k(res_k4, 4)
```

```
## === k = 4 ===
## Silhouette moyenne : 0.1828
## Détail : 0.3536, 0.1734, 0.1281, 0.034
## Dunn : 0.00226
```

Bien que $k = 2$ offre la meilleure qualité statistique avec des clusters très cohérents, une partition en seulement deux groupes est trop simpliste pour refléter la diversité des accidents routiers. Nous retenons donc $k = 3$, qui propose trois profils plus nuancés et interprétables, malgré une qualité statistique légèrement moindre.

```r
table(res_k3$cluster)
```

Distribution des observations par cluster

```
##
##    1    2    3
## 1807 1135 2058
```

F. Comparaison échantillon vs données complètes

Moyennes des variables numériques par cluster

```r
library(clustMixType)

# Moyennes vma
cat("Moyenne vma sur l'échantillon :\n")
```

```
## Moyenne vma sur l'échantillon :
```

```r
print(round(tapply(df$vma, res_k3$cluster, mean), 1))
```

```
##    1    2    3
## 85.8 41.8 49.0
```

```r
res_full <- kproto(df_complete, k = 3, verbose = FALSE)
cat("\nMoyenne vma sur les données complètes :\n")
```

```
##
## Moyenne vma sur les données complètes :
```

```r
print(round(tapply(df_complete$vma, res_full$cluster, mean), 1))
```

```
##    1    2    3
## 48.9 42.3 87.8
```

Répartition des variables catégorielles par cluster

```r
cat_cols <- sapply(df, is.factor)

for (col in names(df)[cat_cols]) {
  cat("\n=== Variable :", col, "===\n\n")

  cat("Échantillon :\n")
  print(table(df[[col]], res_k3$cluster))
```

```r
  cat("\nDonnées complètes :\n")
  print(table(df_complete[[col]], res_full$cluster))

  cat("\n")
}
```

```
##
## === Variable : agg ===
##
## Échantillon :
##
##                 1    2    3
##   en agglo     16 1090 1995
##   hors agglo 1791   45   63
##
## Données complètes :
##
##                  1     2     3
##   en agglo   12540  6938   135
##   hors agglo   789   568 10146
##
##
## === Variable : lum ===
##
## Échantillon :
##
##                                    1    2    3
##   crepuscule ou aube             220  113  209
##   nuit avec eclairage allume      69  350  533
##   nuit avec eclairage non allume  18   13   14
##   nuit sans eclairage            486   53   53
##   plein jour                    1014  606 1249
##
## Données complètes :
##
##                                    1    2    3
##   crepuscule ou aube            1350  768 1189
##   nuit avec eclairage allume    3408 2159  419
##   nuit avec eclairage non allume  137  111  104
##   nuit sans eclairage            417  437 2961
##   plein jour                    8017 4031 5608
##
##
## === Variable : atm ===
##
## Échantillon :
##
##                          1    2    3
##   autre                 28    3   10
##   brouillard ou fumee   33    4    9
##   couvert               75   52   83
##   eblouissant           28   35   33
##   neige ou grele        16    3    6
```

```
##   normale              1375  864 1649
##   pluie forte            49   27   26
##   pluie legere          196  142  239
##   vent fort ou tempete    7    5    3
##
## Données complètes :
##
##                           1     2     3
##   autre                  61    40   120
##   brouillard ou fumee    60    53   215
##   couvert               512   334   420
##   eblouissant           191   192   172
##   neige ou grele         30    28    75
##   normale             10773  5674  7821
##   pluie forte           204   168   250
##   pluie legere         1482  1001  1176
##   vent fort ou tempete   16    16    32
##
##
## === Variable : col ===
##
## Échantillon :
##
##                         1    2    3
##   3+ veh - en chaine  108    5   60
##   3+ veh - multiple    97   11   50
##   autre               465  958    0
##   deux veh - arriere  323   59  295
##   deux veh - cote     324    0 1252
##   deux veh - frontal  218   48  216
##   sans                272   54  185
##
## Données complètes :
##
##                         1    2    3
##   3+ veh - en chaine  414   42  722
##   3+ veh - multiple   342   53  522
##   autre                 0 6380 2579
##   deux veh - arriere 2003  336 1861
##   deux veh - cote    7606    0 1864
##   deux veh - frontal 1620  365 1303
##   sans               1344  330 1430
```

G. Visualisation des clusters k-prototypes

```
library(ggplot2)
library(dplyr)
library(gridExtra)
```

```
##
## Attachement du package : 'gridExtra'
```

```
## L'objet suivant est masqué depuis 'package:dplyr':
##
##     combine
```

```r
library(scales)  # Pour percent()

df_vis <- df %>% mutate(cluster = as.factor(res_k3$cluster))

p1 <- ggplot(df_vis, aes(x = cluster, y = vma, fill = cluster)) +
  geom_boxplot() + theme_minimal() + theme(legend.position = "none") +
  labs(title = "Vitesse maximale autorisée", x = "Cluster", y = "vma (km/h)")

p2 <- ggplot(df_vis, aes(x = cluster, fill = agg)) + geom_bar(position = "fill") +
  scale_y_continuous(labels = percent) + theme_minimal() +
  labs(title = "Localisation", x = "Cluster", y = "Proportion")

p3 <- ggplot(df_vis, aes(x = cluster, fill = lum)) + geom_bar(position = "fill") +
  scale_y_continuous(labels = percent) + theme_minimal() +
  labs(title = "Luminosité", x = "Cluster", y = "Proportion")

p4 <- ggplot(df_vis, aes(x = cluster, fill = atm)) + geom_bar(position = "fill") +
  scale_y_continuous(labels = percent) + theme_minimal() +
  labs(title = "Conditions atmosphériques", x = "Cluster", y = "Proportion")

p5 <- ggplot(df_vis, aes(x = cluster, fill = col)) + geom_bar(position = "fill") +
  scale_y_continuous(labels = percent) + theme_minimal() +
  labs(title = "Type de collision", x = "Cluster", y = "Proportion")
p1
```

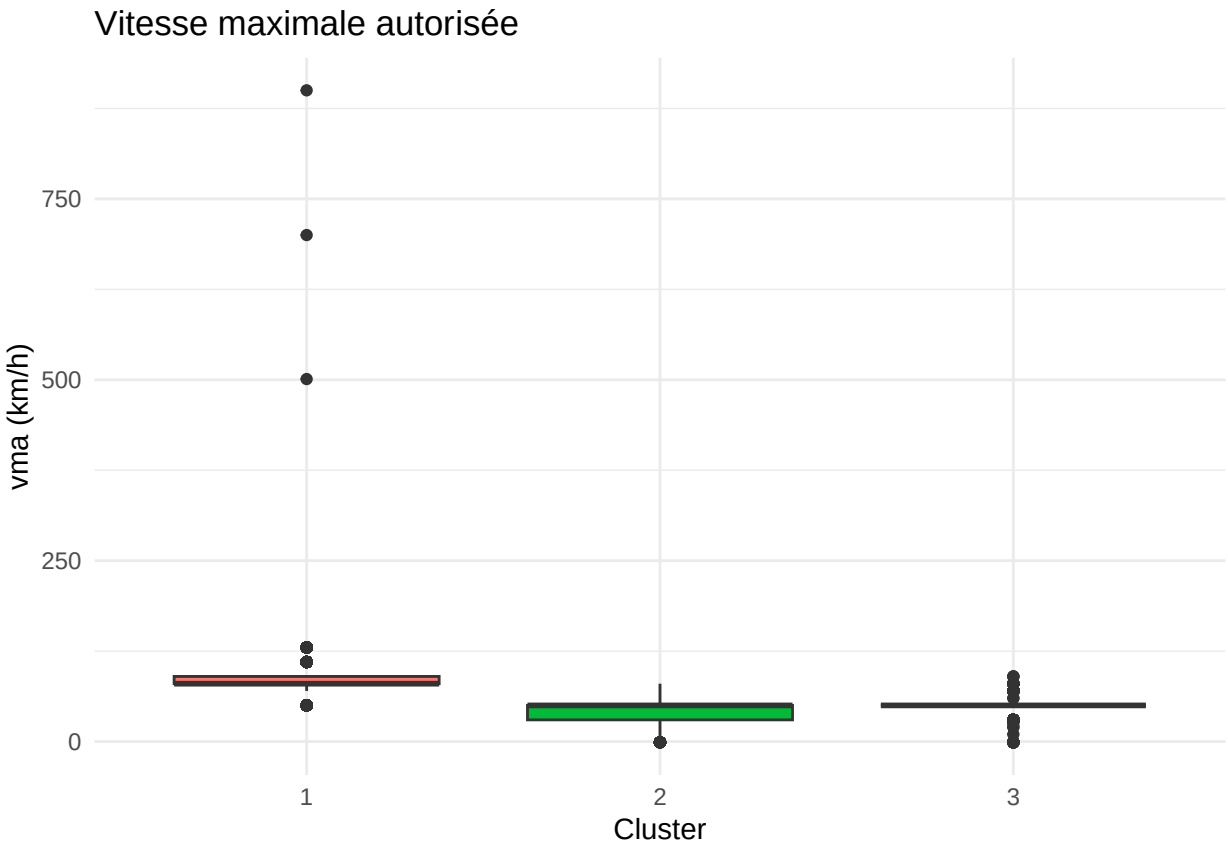
Vitesse maximale autorisée
vma (km/h)
750
500
250
0
1
2
3
Cluster

```
p2
```

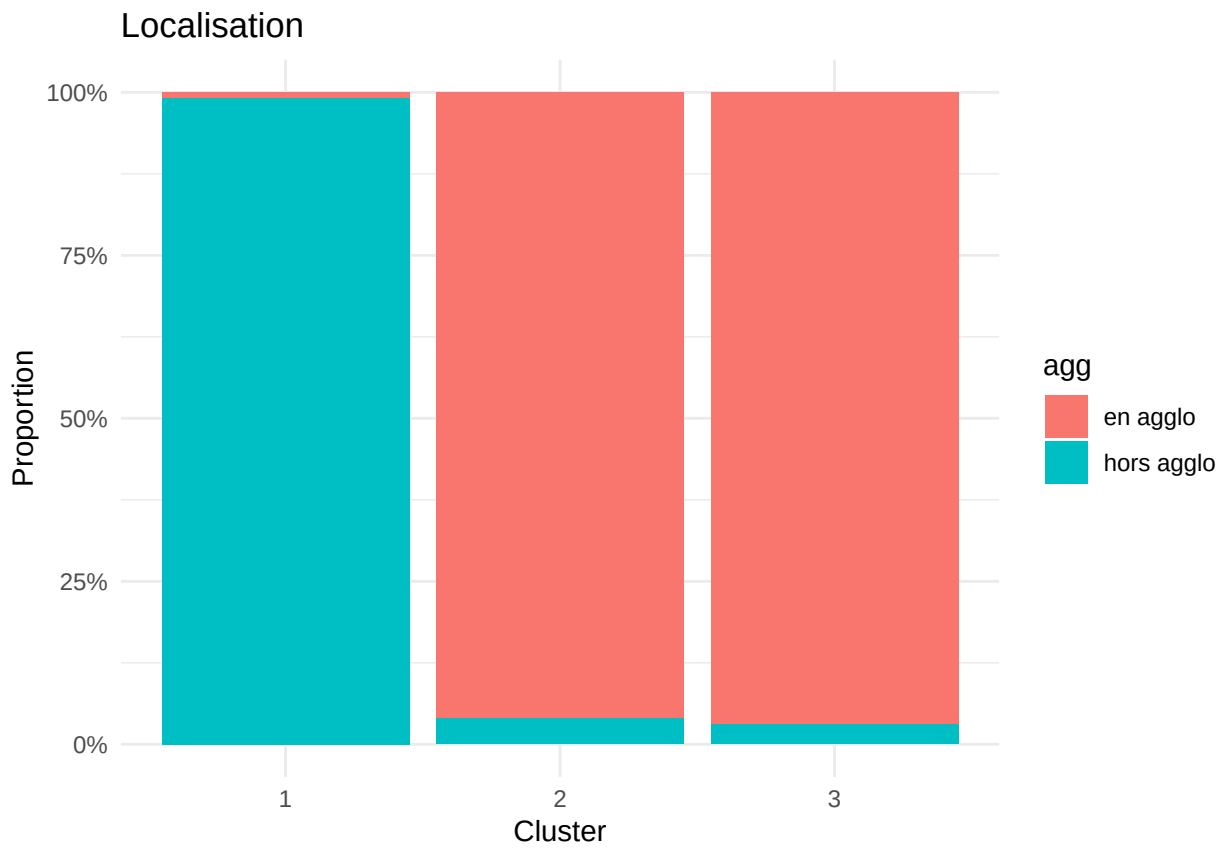
Localisation
100%
75%
50%
25%
0%
Proportion
1
2
3
Cluster
agg
en agglo
hors agglo

```
p3
```

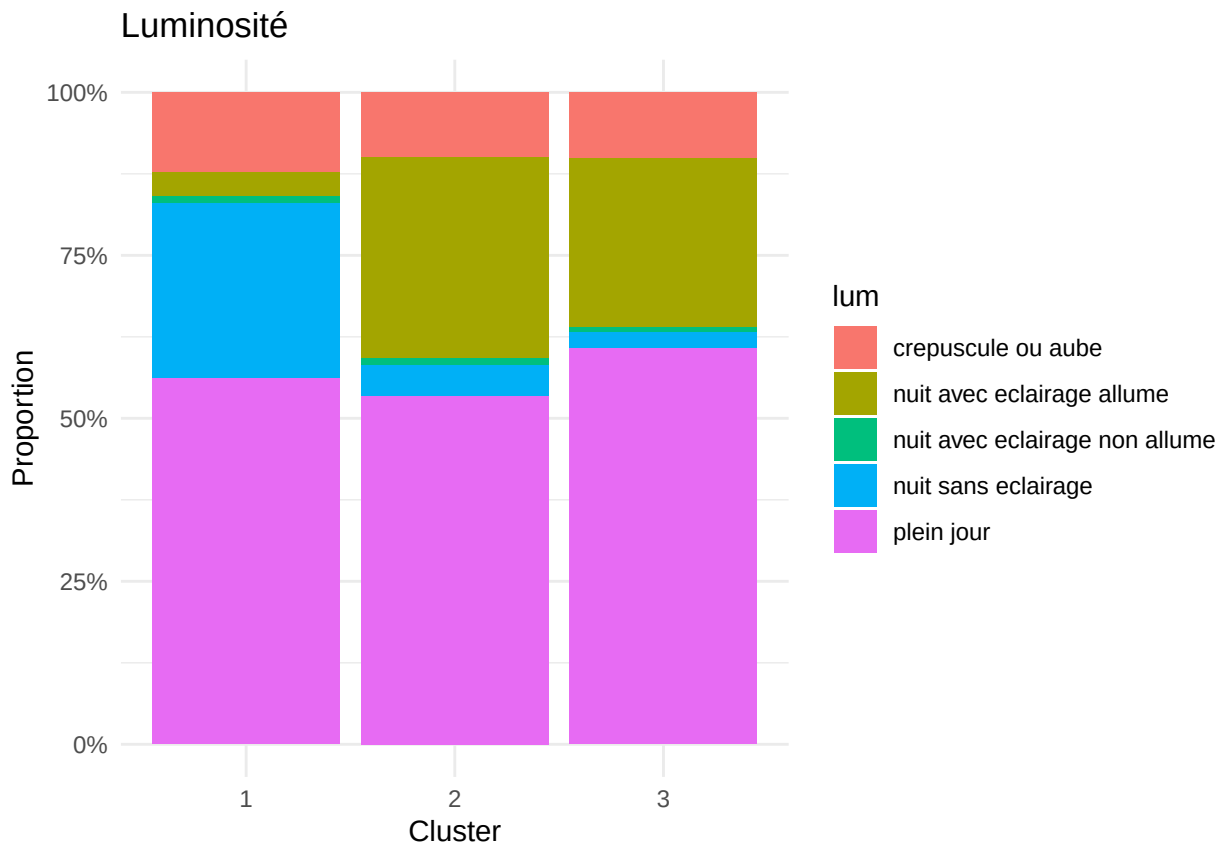
Luminosité
100%
75%
50%
25%
0%
Proportion
1
2
3
Cluster
lum
crepuscule ou aube
nuit avec eclairage allume
nuit avec eclairage non allume
nuit sans eclairage
plein jour

```
p4
```

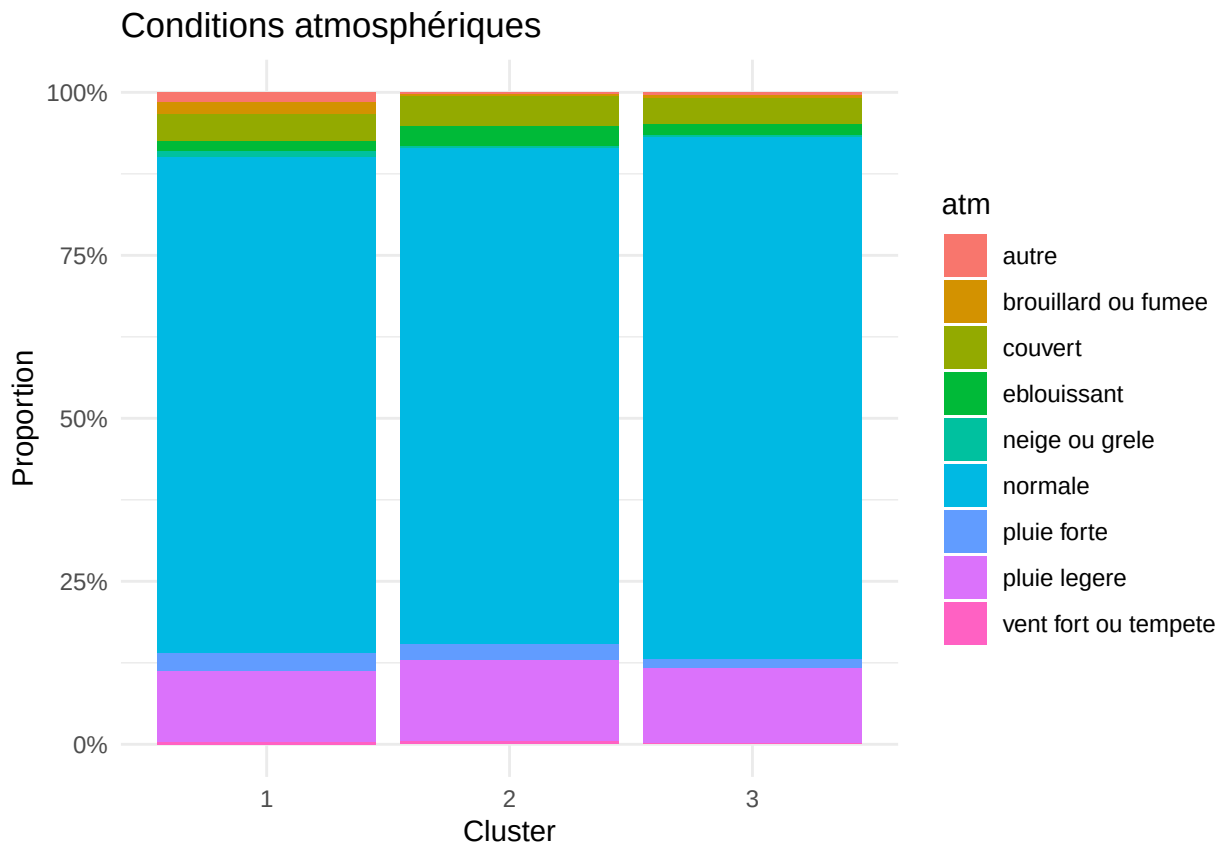
Conditions atmosphériques
100%
75%
50%
25%
0%
Proportion
1
2
3
Cluster
atm
autre
brouillard ou fumee
couvert
eblouissant
neige ou grele
normale
pluie forte
pluie legere
vent fort ou tempete

```
p5
```

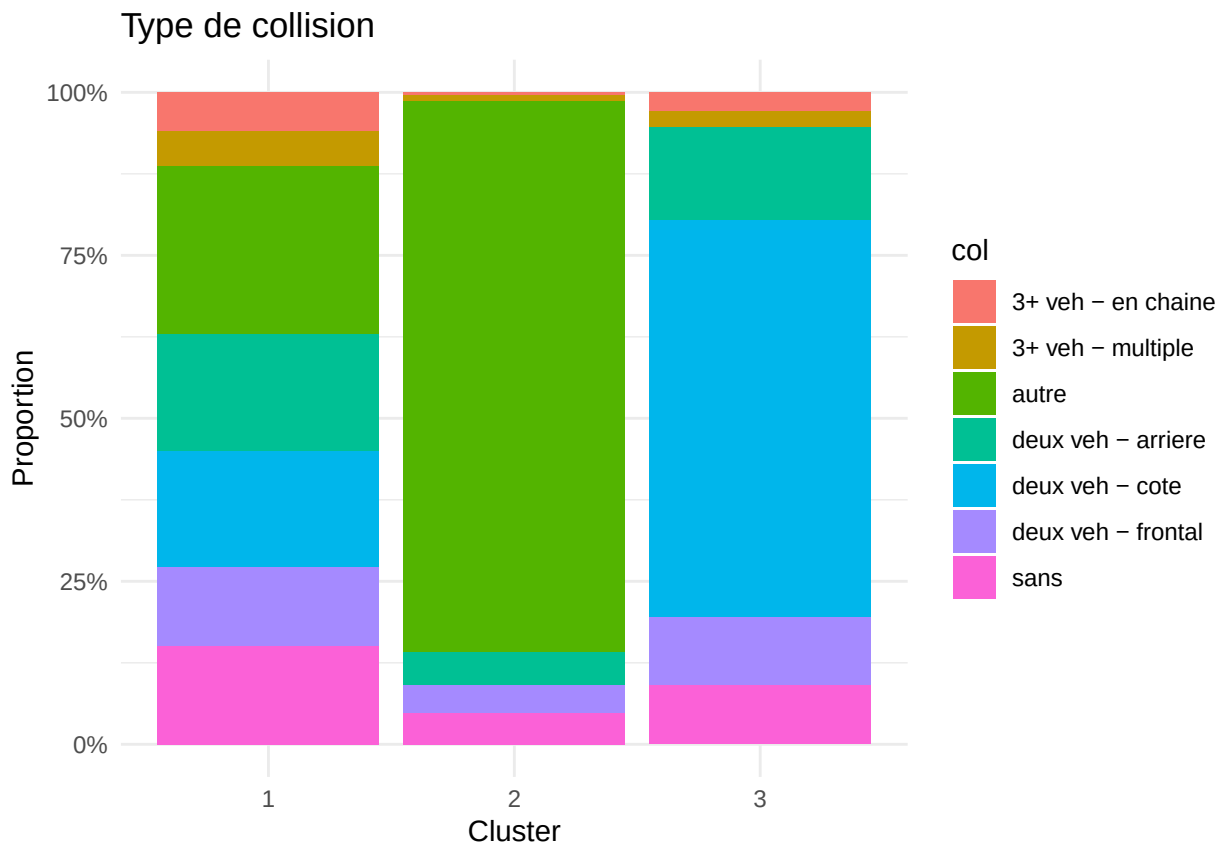


```
set.seed(321)
library(cluster)
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```
library(viridis)
```

```
## Le chargement a nécessité le package : viridisLite

##
## Attachement du package : 'viridis'

## L'objet suivant est masqué depuis 'package:scales':
##
##     viridis_pal
```

```
mds_df <- cmdscale(dist_gower, k = 2) %>% as.data.frame()
colnames(mds_df) <- c("Dim1", "Dim2")

fviz_cluster(list(data = mds_df, cluster = res_k3$cluster),
             geom = "point", palette = viridis(3), ellipse.type = "convex",
             show.clust.cent = TRUE, ggtheme = theme_minimal(),
             main = "Visualisation des clusters") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

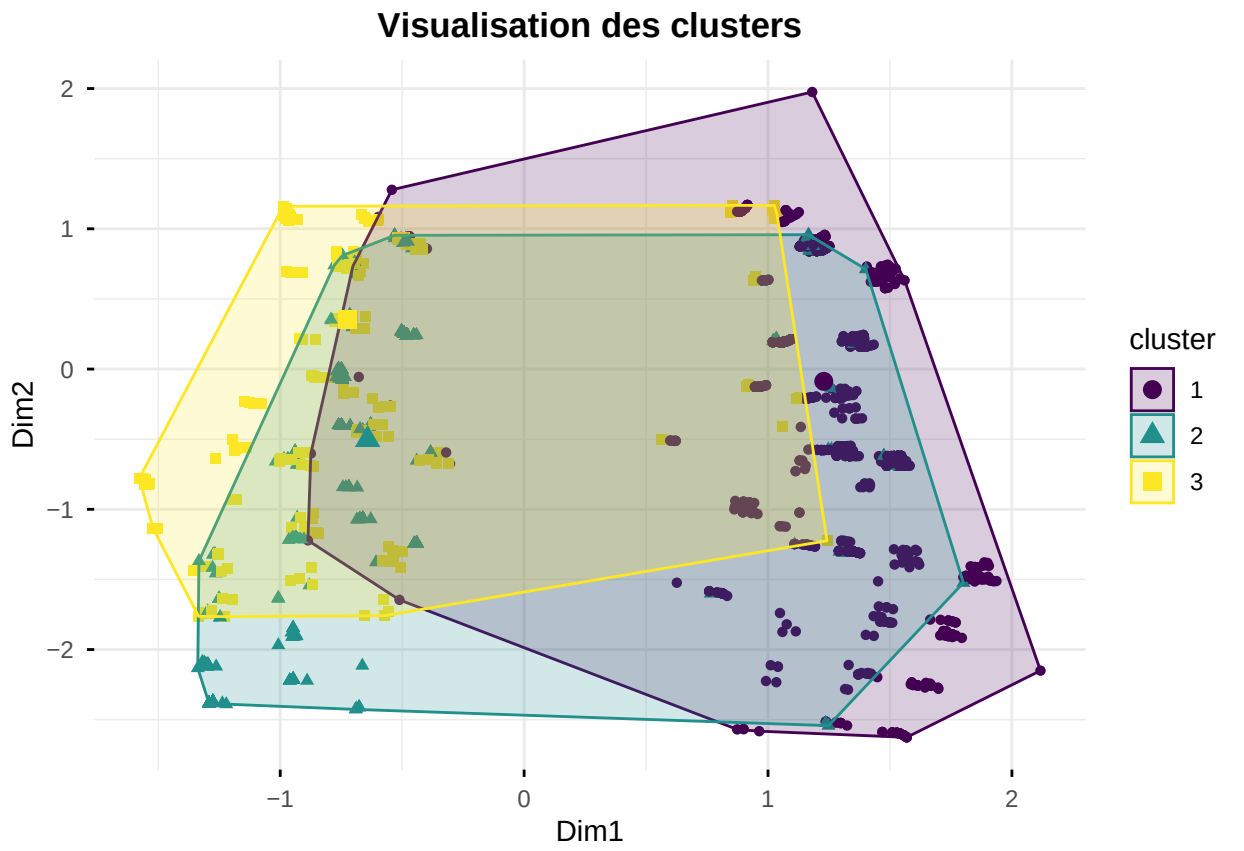


```
ggsave("../Figures/clusters_fviz_final.png", width = 10, height = 8, dpi = 300)
```

Les groupes peuvent se chevaucher car la visualisation 2D (via PCA) projette un espace multidimensionnel sur un simple plan. Cette réduction dimensionnelle entraîne une perte d'information, et des clusters bien séparés dans l'espace original peuvent alors apparaître mélangés sur le graphique.

H. Inteprétation de chaque cluster

Cluster 1 : Accidents Urbains sous Intempéries

Ce groupe se distingue quasi-exclusivement par des conditions météorologiques et de surface dégradées.

- **Conditions :** Forte prédominance de la pluie (légère ou forte) associée à une surface mouillée.
- **Localisation :** Majoritairement en agglomération.
- **Véhicules impliqués :** Une surreprésentation notable des transports en commun, suggérant des problématiques de freinage ou d'adhérence impliquant des véhicules lourds dans un trafic dense.
- **Cinétique :** Vitesse moyenne faible.

Cluster 2 : Accidents de Flux Urbain

Il s'agit du segment le plus volumineux, représentant l'accidentologie "quotidienne" en ville par conditions normales.

- **Configuration :** Exclusivement en agglomération, concentré sur les intersections (carrefours, giratoires) avec une prédominance de chocs latéraux (refus de priorité, changements de file).
- **Usagers Vulnérables :** Forte implication des deux-roues (vélos et motos).
- **Conditions :** Environnement favorable (plein jour, météo normale, surface sèche).
- **Cinétique :** Vitesse moyenne la plus basse des trois groupes.

Cluster 3 : Accidents Routiers à Haute Cinétique

Ce cluster regroupe les accidents hors agglomération, caractérisés par une dangerosité potentielle accrue due à la vitesse.

- **Localisation :** Routes départementales et autoroutes (hors agglomération).
- **Facteurs aggravants :** Surreprésentation des accidents nocturnes ("Nuit sans éclairage") et des tracés en courbe.
- **Typologie :** Nombreuses pertes de contrôle (sorties de route sur accotement) ou chocs frontaux.
- **Véhicules :** Implication majeure des véhicules légers et poids lourds ; absence quasi-totale d'usagers vulnérables (piétons/vélos).
- **Cinétique :** Vitesse moyenne très élevée.

I. Conclusion

L'algorithme K-prototypes a identifié trois groupes d'accidents distincts en combinant variables numériques et catégorielles. Cette segmentation permet d'analyser les différents profils d'accidents et d'identifier les facteurs de risque spécifiques à chaque groupe.